

# Bazēs

---

4 rūšys molekulių, dvi grupės

Adeninas(A), Guaninas(G)

← Purinai

Citozinas(C), Timinas(T)

← Pirimidinai




# Bazès

---

A visada stovi prieš T

G visada stovi prieš C



## Bazēs

---

A visada stovi priēš T

G visada stovi priēš C

Seka:

AGCGCT


Komplementari seka:

TCGCGA

## Bazēs

---

- Tam kad apibūdoti DNR seku użtenka išvadinti DNR bazeš vienoje grandinėje.



## Mutacijos

---

- Mutacijos DNR sekoje atsiranda **atsitiktinai**. Žmogus turi apie ~40 mutacijų atsitiktinai atsiradusių ir nerastų nei viename tėve.

# Mutacijos

---


- Mutacijos DNR sekoje atsiranda **atsitiktinai**.



## Bazių pakeitimas

---


- Dažniausia mutacijų forma
- Bazė yra pakeičiama kita baze



## Bazių pakeitimas


---

- Tranzicija: Pur į Pur, Pyr į Pyr
- Transversija: Pur į Pyr, Pyr į Pur





# Bazių pakeitimas



## **Esminis klausimas**

---

- Kaip nuspręsti kiek mutacijų skiria sekas?

## Pavyzdys

---

S0 : Bendras protėvis

S1 : Palikuonis sekos S0

S2 : Palikuonis sekos S1

S0 : ATGTCGCCTGATAATGCC...

S2 : ATGCCGCGTGATAATGCC...

## Pavyzdys

---

S0 : Bendras protėvis

S1 : Palikuonis sekos S0

S2 : Palikuonis sekos S1

S0 : ATGTCGCCCTGATAATGCC...



S2 : ATGCCGCCGTGATAATGCC...

Stebimų mutacijų skaičius: 2

## Pavyzdys

---

S0 : Bendras protėvis

S1 : Palikuonis sekos S0

S2 : Palikuonis sekos S1

S0 :	ATG	TCGC	CTG	ATA	ATGCC...
S1 :	ATG	CCGCT	TGAC	A	ATGCC...
S2 :	ATG	CCGCG	TGAT	A	ATGCC...

Faktinis mutacijų skaičius: 5

## Pavyzdys

---

S0 : Bendras protėvis

S1 : Palikuonis sekos S0

S2 : Palikuonis sekos S1

S0 : ATGTCGCCTGATAATGCC...  
S1 : ATGCCGCTTGACAATGCC...  
S2 : ATGCCGCGTGATAATGCC...

The diagram shows three DNA sequences aligned. Red arrows point from S0 to S1 at positions 4, 7, and 10. Red arrows point from S1 to S2 at positions 7 and 10. The sequences are: S0: ATGTCGCCTGATAATGCC..., S1: ATGCCGCTTGACAATGCC..., S2: ATGCCGCGTGATAATGCC...

Faktinis mutacijų skaičius: 5  
(dalis yra *paslėptos mutacijos*)

## Ko mes norime?

---

- Palyginti pradinę ir galutinę DNR seką?
- Sukurti matematinį modelį rasti visas įvykusias mutacijas įtraukiant ir paslėptas mutacijas.

## Reality...

---

- Beveik niekada neturime protėvio sekos. Tik kartais turime keletą susijusių organizmų iš praeities.
- Dažniausiai turime sekas tik dabar gyvenančių palikuonių, bet niekada neturime informacijos apie dabar neegzistuojančių organizmų sekas.



## Realybė...

---

- Kai mes lyginame dvi sekas ir bandome atkurti mutacijas, kurioms vykstant jos atsirado, mes nežinome ***paskutinio bendro protėvio*** sekos.

## Ortologinės sekos

---

- Duotai DNR sekai mes galime rasti panašias sekas DNR duombazėse.
- Jei genas randamas viename organizme, mes galime greitai identifikuoti panašių genų sekas susijusiuose organizmuose.

## Ortologinės sekos

---

- Jei genas turi panašią funkciją, mes galime pagrįstai teikti kad jos kilo iš bendro protėvio ir yra *ortologinė*.

# **Sąliginė tikimybė**

---

## Apibrėžimas

---

Esant dviems galimiems įvykiams  $E$  ir  $F$ , sąlyginė tikimybė kad įvyks įvykis  $E$  įvykus įvykiui  $F$  apibrėžiama taip:

$$P(F | E) = \frac{P(F \cap E)}{P(E)}$$

## Pavyzdys

---

Tarkim yra 40-bazių ilgio protėvio seka  $S_0$  ir palikuonio seka  $S_1$

$S_0$  : *ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT*

$S_1$  : *ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC*

## Example

Suskaičiuojam įvykusius bazių pakeitimus:

$S_0$  : *ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT*  
 $S_1$  : *ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC*

$S_1 \setminus S_0$	<i>A</i>	<i>G</i>	<i>C</i>	<i>T</i>
<i>A</i>	7	0	1	1
<i>G</i>	1	9	2	0
<i>C</i>	0	2	7	2
<i>T</i>	1	0	1	6

## Example

---

Galime įvertinti  $P(S_1 = i \mid S_0 = j)$

$S_0 : ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT$

$S_1 : ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC$

$S_1 \setminus S_0$	$A$	$G$	$C$	$T$
$A$	7	0	1	1
$G$	1	9	2	0
$C$	0	2	7	2
$T$	1	0	1	6



## Example

Galime įvertinti  $P(S_1 = i \mid S_0 = j)$

$S_0 : ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT$

$S_1 : ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC$

$S_1 \setminus S_0$	$A$	
$A$	7	$P(S_1 = A \mid S_0 = A) = \frac{7}{9}$
$G$	1	$P(S_1 = G \mid S_0 = A) = \frac{1}{9}$
$C$	0	$P(S_1 = C \mid S_0 = A) = 0$
$T$	1	$P(S_1 = T \mid S_0 = A) = \frac{1}{9}$

## Example

---

Q1: Kokia suma yra 16-os langelių? Kodėl?

$S_0$  : *ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT*

$S_1$  : *ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC*

$S_1 \setminus S_0$	<i>A</i>	<i>G</i>	<i>C</i>	<i>T</i>
<i>A</i>	7	0	1	1
<i>G</i>	1	9	2	0
<i>C</i>	0	2	7	2
<i>T</i>	1	0	1	6

## Example

---

Kam lygios eilučių sumos?

$S_0$  : *ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT*

$S_1$  : *ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC*

$S_1 \setminus S_0$	<i>A</i>	<i>G</i>	<i>C</i>	<i>T</i>
<i>A</i>	7	0	1	1
<i>G</i>	1	9	2	0
<i>C</i>	0	2	7	2
<i>T</i>	1	0	1	6

## Example

---

Galime sudaryti sąlyginės tikimybės matricą  $P(S_1 = i \mid S_0 = j)$

$S_1 \setminus S_0$	$A$	$G$	$C$	$T$
$A$	$\frac{7}{9}$	$0$	$\frac{1}{11}$	$\frac{1}{9}$
$G$	$\frac{1}{9}$	$\frac{9}{11}$	$\frac{2}{11}$	$0$
$C$	$0$	$\frac{2}{11}$	$\frac{7}{11}$	$\frac{2}{9}$
$T$	$\frac{1}{9}$	$0$	$\frac{1}{11}$	$\frac{6}{9}$

## Example

---

Kokia yra suma kiekvieno stulpelio? Kodėl?

$S_1 \setminus S_0$	$A$	$G$	$C$	$T$
$A$	$\frac{7}{9}$	$0$	$\frac{1}{11}$	$\frac{1}{9}$
$G$	$\frac{1}{9}$	$\frac{9}{11}$	$\frac{2}{11}$	$0$
$C$	$0$	$\frac{2}{11}$	$\frac{7}{11}$	$\frac{2}{9}$
$T$	$\frac{1}{9}$	$0$	$\frac{1}{11}$	$\frac{6}{9}$

## Pavyzdys

40-bazių ilgio protėvio seka  $S_0$  ir palikuonio seka  $S_1$ . Turim sąlyginės tikimybės matricą.

$S_0 : ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT$

$S_1 : ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC$

$S_1 \setminus S_0$	A	G	C	T
A	7	0	1	1
G	1	9	2	0
C	0	2	7	2
T	1	0	1	6

$S_1 \setminus S_0$	A	G	C	T
A	$\frac{7}{9}$	0	$\frac{1}{11}$	$\frac{1}{9}$
G	$\frac{1}{9}$	$\frac{9}{11}$	$\frac{2}{11}$	0
C	0	$\frac{2}{11}$	$\frac{7}{11}$	$\frac{2}{9}$
T	$\frac{1}{9}$	0	$\frac{1}{11}$	$\frac{6}{9}$

$$P(S_1 = i \mid S_0 = j)$$

## Apibrėžimai

---

$$P_i = P(\text{ } i \text{ tipo bazė } \text{ }), i \in \Omega = \{A, G, C, T\}$$

$$P_{i|j} = P(S_1 = i \mid S_0 = j), i \in \Omega$$

Kiekvienai sekai  $S_k$  galimpirėžti pasiskirstymo vektorių  $p_k$

$$p_k = \begin{bmatrix} P_A & P_G & P_C & P_T \end{bmatrix}^T$$

# Pavyzdys

$$p_0 = [P_A \quad P_G \quad P_C \quad P_T]^T = \left[ \frac{9}{40} \quad \frac{11}{40} \quad \frac{11}{40} \quad \frac{9}{40} \right]^T$$

$S_0 : \text{ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT}$

$S_1 : \text{ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC}$

$S_1 \setminus S_0$	A	G	C	T
A	7	0	1	1
G	1	9	2	0
C	0	2	7	2
T	1	0	1	6

$S_1 \setminus S_0$	A	G	C	T
A	$\frac{7}{9}$	0	$\frac{1}{11}$	$\frac{1}{9}$
G	$\frac{1}{9}$	$\frac{9}{11}$	$\frac{2}{11}$	0
C	0	$\frac{2}{11}$	$\frac{7}{11}$	$\frac{2}{9}$
T	$\frac{1}{9}$	0	$\frac{1}{11}$	$\frac{6}{9}$

$$P_{i|j} = P(S_1 = i \mid S_0 = j)$$



# Pavyzdys

$$p_1 = [P_A \quad P_G \quad P_C \quad P_T]^T = \left[ \frac{9}{40} \quad \frac{12}{40} \quad \frac{11}{40} \quad \frac{8}{40} \right]^T$$

$S_0 : ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT$

$S_1 : ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC$

$S_1 \setminus S_0$	A	G	C	T
A	7	0	1	1
G	1	9	2	0
C	0	2	7	2
T	1	0	1	6

$S_1 \setminus S_0$	A	G	C	T
A	$\frac{7}{9}$	0	$\frac{1}{11}$	$\frac{1}{9}$
G	$\frac{1}{9}$	$\frac{9}{11}$	$\frac{2}{11}$	0
C	0	$\frac{2}{11}$	$\frac{7}{11}$	$\frac{2}{9}$
T	$\frac{1}{9}$	0	$\frac{1}{11}$	$\frac{6}{9}$

$$P_{i|j} = P(S_1 = i | S_0 = j)$$

## Pavyzdys

Kokia yra sąsaja tarp  $p_0$ ,  $p_1$  ir  $p_{ij}$ ?

$$p_0 = \begin{bmatrix} \frac{9}{40} & \frac{11}{40} & \frac{11}{40} & \frac{9}{40} \end{bmatrix}^T$$

$$p_1 = \begin{bmatrix} \frac{9}{40} & \frac{12}{40} & \frac{11}{40} & \frac{8}{40} \end{bmatrix}^T$$

$S_1 \setminus S_0$	$A$	$G$	$C$	$T$
$A$	$\frac{7}{9}$	0	$\frac{1}{11}$	$\frac{1}{9}$
$G$	$\frac{1}{9}$	$\frac{9}{11}$	$\frac{2}{11}$	0
$C$	0	$\frac{2}{11}$	$\frac{7}{11}$	$\frac{2}{9}$
$T$	$\frac{1}{9}$	0	$\frac{1}{11}$	$\frac{6}{9}$

$$P_{i|j} = P(S_1 = i \mid S_0 = j)$$

## Perėjimo matrica

---

- Užkoduokime sąlygines tikimybes į matricą.

$$M = [P_{i|j}] = \begin{bmatrix} P_{A|A} & P_{A|G} & P_{A|C} & P_{A|T} \\ P_{G|A} & P_{G|G} & P_{G|C} & P_{G|T} \\ P_{C|A} & P_{C|G} & P_{C|C} & P_{C|T} \\ P_{T|A} & P_{T|G} & P_{T|C} & P_{T|T} \end{bmatrix}$$

# Pavyzdys

$$P_{i|j} = P(S_1 = i | S_0 = j)$$

$$M = \begin{bmatrix} P_{A|A} & P_{A|G} & P_{A|C} & P_{A|T} \\ P_{G|A} & P_{G|G} & P_{G|C} & P_{G|T} \\ P_{C|A} & P_{C|G} & P_{C|C} & P_{C|T} \\ P_{T|A} & P_{T|G} & P_{T|C} & P_{T|T} \end{bmatrix} = \begin{bmatrix} \frac{7}{9} & 0 & \frac{1}{11} & \frac{1}{9} \\ \frac{1}{9} & \frac{9}{11} & \frac{2}{11} & 0 \\ 0 & \frac{2}{11} & \frac{7}{11} & \frac{2}{9} \\ \frac{1}{9} & 0 & \frac{1}{11} & \frac{6}{9} \end{bmatrix}$$

$S_1 \setminus S_0$	$A$	$G$	$C$	$T$
$A$	$\frac{7}{9}$	0	$\frac{1}{11}$	$\frac{1}{9}$
$G$	$\frac{1}{9}$	$\frac{9}{11}$	$\frac{2}{11}$	0
$C$	0	$\frac{2}{11}$	$\frac{7}{11}$	$\frac{2}{9}$
$T$	$\frac{1}{9}$	0	$\frac{1}{11}$	$\frac{6}{9}$

## Pavyzdys

---

$$p_1 = Mp_0$$

$$\begin{bmatrix} \frac{9}{40} \\ \frac{12}{40} \\ \frac{11}{40} \\ \frac{8}{40} \end{bmatrix} = \begin{bmatrix} \frac{7}{9} & 0 & \frac{1}{11} & \frac{1}{9} \\ \frac{1}{9} & \frac{9}{11} & \frac{2}{11} & 0 \\ 0 & \frac{2}{11} & \frac{7}{11} & \frac{2}{9} \\ \frac{1}{9} & 0 & \frac{1}{11} & \frac{6}{9} \end{bmatrix} \begin{bmatrix} \frac{9}{40} \\ \frac{11}{40} \\ \frac{11}{40} \\ \frac{9}{40} \end{bmatrix}$$

## Pavyzdys

---

$$p_1 = Mp_0$$

$$\begin{bmatrix} \frac{9}{40} \\ \frac{12}{40} \\ \frac{11}{40} \\ \frac{8}{40} \end{bmatrix} = \begin{bmatrix} \frac{7}{9} & 0 & \frac{1}{11} & \frac{1}{9} \\ \frac{1}{9} & \frac{9}{11} & \frac{2}{11} & 0 \\ 0 & \frac{2}{11} & \frac{7}{11} & \frac{2}{9} \\ \frac{1}{9} & 0 & \frac{1}{11} & \frac{6}{9} \end{bmatrix} \begin{bmatrix} \frac{9}{40} \\ \frac{11}{40} \\ \frac{11}{40} \\ \frac{9}{40} \end{bmatrix}$$

Kodėl?

# Pavyzdys

$$p_1 = Mp_0$$

$$\begin{bmatrix} \frac{9}{40} \\ \frac{12}{40} \\ \frac{11}{40} \\ \frac{8}{40} \end{bmatrix} = \begin{bmatrix} \frac{7}{9} & 0 & \frac{1}{11} & \frac{1}{9} \\ \frac{1}{9} & \frac{9}{11} & \frac{2}{11} & 0 \\ 0 & \frac{2}{11} & \frac{7}{11} & \frac{2}{9} \\ \frac{1}{9} & 0 & \frac{1}{11} & \frac{6}{9} \end{bmatrix} \begin{bmatrix} \frac{9}{40} \\ \frac{11}{40} \\ \frac{11}{40} \\ \frac{9}{40} \end{bmatrix}$$

Kodėl?

## Pavyzdys

---

$$\begin{bmatrix} ? \end{bmatrix} = \begin{bmatrix} P_{A|A} & P_{A|G} & P_{A|C} & P_{A|T} \\ P_{G|A} & P_{G|G} & P_{G|C} & P_{G|T} \\ P_{C|A} & P_{C|G} & P_{C|C} & P_{C|T} \\ P_{T|A} & P_{T|G} & P_{T|C} & P_{T|T} \end{bmatrix} \begin{bmatrix} P(S_0 = A) \\ P(S_0 = G) \\ P(S_0 = C) \\ P(S_0 = T) \end{bmatrix}$$



## Estimation

---

- Naudojant perėjimo matricą galime įvertinti bazių pasiskirstymo vektorių  $p_k$  palikuonių kartų sekose.  $S_k, k = 1, 2, 3, \dots$

$$p_k = Mp_{k-1}$$

$$M = [P_{i|j}] = [P(S_k = i | S_{k-1} = j)]$$

## Kas iš to?

---

- Galime modeliuoti mutacijų dažnius ir jų pokyčius iš kartos į kartą įvertinant ir įvykusias paslėptas mutacijas mutacijas

S0 : ATGTCGCCTGATAATGCC...

S1 : ATGCCGCTTGACAATGCC...

S2 : ATGCCGCGTGATAATGCC...

Faktinis mutacijų skaičius: 5  
(dalis yra *paslėptos mutacijos*)

## **Kam to reikia**

---

- Galime rasti tikrus atstumus tarpseky

## Atstumas tarp diejų sekų

---

- Filogenezeje reikia apibrėžti atstumą tarp dviejų sekų.
- Jis turi parodyti vidutinį mutacijų dažnį per poziciją, įskaitant nematomas mutacijas.

S0 : ATGTCGCCTGATAATGCC...

⋮

⋮

S : ATGCCGCGTGATAATGCC...

## Atstumas tarp diejų sekų

---

- Matematiniai modeliai
  - Jukes-Cantor
  - Kimura

## Jukes-Cantor modelis

---

### Prielaidos

- Bazių pakeitimo (mutacijų) tikimybė išlieka pastovi iš kartos į kartą.
- Mutacijos sekai  $S_{k-1}$  virstant seka  $S_k$  priklauso tik nuo sekos  $S_{k-1}$ .
- Bazė mutuoti į be kurią kitą bazę turi vienodą tikimybę.

## Jukes-Cantor modelis

---

DNR pakaitai

- Ilgą laiką nukleotidas duotoje pozicijoje išlieka tas pats.
- Bet periodiškai tas nukleotidas pasikeičia (visoje populiacijoje)
- Tai vadinama pakaita - kai dominuojantis nukleotidas konkrečioje pozicijoje pakeičiamas kitu.

# Jukes-Cantor modelis

---

Markov'o grandinė pakaitų modeliavimui

- Galimos keturios būklės “a”, “c”, “g”, “t”
- Grandinė veikia bėgant laiko vienetams - būklė gali pasikeisti einant nuo vieno laiko taško prie kito
- Laiko vienetui gali būti pasirenkami bet kaip (tarkim kas 20000 generacijų)



## Jukes-Cantor modelis

---

### Prielaidos

- Bazių pakeitimo (mutacijų) tikimybė išlieka pastovi iš kartos į kartą.
- Mutacijos sekai  $S_{k-1}$  virstant seka  $S_k$  priklauso tik nuo sekos  $S_{k-1}$ .
- Bazė mutuoti į be kurią kitą bazę turi vienodą tikimybę.

## Jukes-Cantor modelis

---

- Tarkim kad  $\alpha$  yra mažas.
- Mutacijos yra "retos"

Perėjimo matrica **P**

	A	C	G	T
A	$1-\alpha$	$\alpha/3$	$\alpha/3$	$\alpha/3$
C	$\alpha/3$	$1-\alpha$	$\alpha/3$	$\alpha/3$
G	$\alpha/3$	$\alpha/3$	$1-\alpha$	$\alpha/3$
T	$\alpha/3$	$\alpha/3$	$\alpha/3$	$1-\alpha$

## Jukes-Cantor modelis

---

- Tarkim kad  $\alpha$  yra mažas.
- Mutacijos yra "retos"

Perėjimo matrica **P**

$\alpha$  yra parametras  
priklausantis nuo to, ką  
reiškia laiko vienetas.

Jei laiko vienetas atitinka  
daug generacijų,  $\alpha$  bus  
didesnis

	A	C	G	T
A	$1-\alpha$	$\alpha/3$	$\alpha/3$	$\alpha/3$
C	$\alpha/3$	$1-\alpha$	$\alpha/3$	$\alpha/3$
G	$\alpha/3$	$\alpha/3$	$1-\alpha$	$\alpha/3$
T	$\alpha/3$	$\alpha/3$	$\alpha/3$	$1-\alpha$

# Jukes-Cantor modelis

---

- $\alpha$  yra parametras priklausantis nuo to, ką reiškia laiko vienetas.
- Jei laiko vienetas atitinka daug generacijų,  $\alpha$  bus didesnis
- $\alpha$  - bazės pakeitimo sekos pozicijoje tikimybė per laiko vieneta.
- Pakeitimas reiškia, kad yra 3 galimi pakeitimai (pvz.  $C \rightarrow \{A, G, T\}$ )
- Nesant bazės pakeitimui yra viena galimybė (pvz.  $C \rightarrow C$ )

	A	C	G	T
A	$1-\alpha$	$\alpha/3$	$\alpha/3$	$\alpha/3$
C	$\alpha/3$	$1-\alpha$	$\alpha/3$	$\alpha/3$
G	$\alpha/3$	$\alpha/3$	$1-\alpha$	$\alpha/3$
T	$\alpha/3$	$\alpha/3$	$\alpha/3$	$1-\alpha$

## Jukes-Cantor modelis. Supratimui.

---

- Tarkim yra perėjimo matrica  $\mathbf{P}$ , ir tikimybių vektorius  $\mathbf{v}$  (eilutė)
- Ką  $\mathbf{w} = \mathbf{v} \mathbf{P}$  atitiktų ?
- Jei  $\mathbf{v}$  atitinka keturių nukleotidų esamą pasiskirstymą pozicijoje, tai  $\mathbf{w}$  atitiktų nukleotidų pasiskirstymą sekančiu laiko momentu.

## Jukes-Cantor modelis. Supratimui.

---

- Tarkim, kad mes galime rasti tokį vektorių  $\phi$ , kad  $\phi P = \phi$
- Jei tikimybių pasiskirstymas yra  $\phi$ , tai jis ir ateityje bus lygus  $\phi$  ateityje.
- Tai vadinama stacionariu Markovo grandinės pasiskirstymu.

## Jukes-Cantor modelis. Supratimui.

---

- Galima patikrinti, kad vektorius  $\phi = (0.25, 0.25, 0.25, 0.25)$  tenkina sąlygą  $\phi P = \phi$
- Taigi jei pozicija vystysis pakankamai ilgai, bus vienodos galimybės visiems keturiems nukleotidams joje būti.
- Tai labai ilgo laikotarpio spėjimas...bet ar galime išreikšti nukleotidų pasiskirstymą pozicijoje laiko funkcija?

## Spektrinė dekompozicija

---

- Atsiminkit radom  $\phi$  tokį, kad
- $\phi P = \phi$
- Toks vektorius vadinamas **tikriniu vektoriumi**, o atitinkanti **tikrinė vertė** yra 1.
- Apskritai jei  $u P = \lambda u$  (sakalaras  $\lambda$ ),  $\lambda$  yra vadinama tikrine verte ir  $u$  yra kairysis tikrinis vektorius  $P$  matricai.



# Spektrinė dekompozicija

- Panašiai jei  $P v^T = \lambda v^T$ , tai  $u$  yra vadinamas dešniuoju tikriniu vektoriumi.
- Apskritai gali būti daug tikrinių verčių  $\lambda_j$  ir atitinkamų kairiųjų ir dešiniųjų tikrinių vektorių  $u_j$  ir  $v_j$ .
- Taigi galime parašyti  $P$  kaip:

$$P = \sum_j \lambda_j u_j v_j^T$$

	A	C	G	T
A	$1-\alpha$	$\alpha/3$	$\alpha/3$	$\alpha/3$
C	$\alpha/3$	$1-\alpha$	$\alpha/3$	$\alpha/3$
G	$\alpha/3$	$\alpha/3$	$1-\alpha$	$\alpha/3$
T	$\alpha/3$	$\alpha/3$	$\alpha/3$	$1-\alpha$

- Kadangi mūsų matrica  $P$  yra simetriška, tai kairysis tikrinis vektorius yra lygu dešiniojo tikrinio vektoriaus (tai pačiai tikrinei vertei) transpozicijai. Taigi  $u_j = v_j$  ir  $P$  galime parašyti kaip:

$$P = \sum_j \lambda_j v_j v_j^T$$

# Spektrinė dekompozicija

- Matricos P tikriniai vektoriai  $v_n$  ir tikrinės vertės  $\lambda_n$

Matrica P

$$\lambda_1 = 1: v_1 = 1/4 (1 \ 1 \ 1 \ 1)^T$$

$$\lambda_{2..4} = 1-4\alpha/3:$$

$$v_2 = 1/4 (-1 \ -1 \ 1 \ 1)^T$$

$$v_3 = 1/4 (-1 \ -1 \ -1 \ 1)^T$$

$$v_4 = 1/4 (1 \ -1 \ 1 \ -1)^T$$

	A	C	G	T
A	$1-\alpha$	$\alpha/3$	$\alpha/3$	$\alpha/3$
C	$\alpha/3$	$1-\alpha$	$\alpha/3$	$\alpha/3$
G	$\alpha/3$	$\alpha/3$	$1-\alpha$	$\alpha/3$
T	$\alpha/3$	$\alpha/3$	$\alpha/3$	$1-\alpha$

$$P = \sum_j \lambda_j v_j v_j^T$$

# Spektrinė dekompozicija

---

- Tuomet, kiekvienam teigiamam sveikam skaičiui  $t$  bus teisinga lygybė

$$P^t = \sum_j \lambda_j^t v_j v_j^T$$

- Kodėl  $P^t$  mums turi rūpėti?
- Todėl, kad  $P^t$  mums parodo, koks bus pasiskirstymas bazių po  $t$  laiko žingsnių.
- Jeigu bazių pasiskirstymas pozicijoje pradžioje buvo lygus vektoriuo  $v^T$ , tai tada  $P^t v^T$  bus atitinkamas pasiskirstymas po  $t$  laiko žingsnių.

## Grižtant prie Jukes-Cantor modelio

- Minėjome, kad  $\phi = (.25, .25, .25, .25)$  yra kairysis  $P$  matricos tikrinis vektorius su tikrine verte .
- Kaip jau rodyta, J-C perėjimo matrica  $P$  be šios tikrinės vertės turi tikrinę vertę  $(1-4\alpha/3)$  ir po matematinių manipuliacijų gautume šios matricos  $P$  tokią spektrinę dekompoziciją:

$$P^t = \sum_j \lambda_j^t v_j v_j^T$$

$$P^t = \begin{bmatrix} 1/4 & 1/4 & 1/4 & 1/4 \\ 1/4 & 1/4 & 1/4 & 1/4 \\ 1/4 & 1/4 & 1/4 & 1/4 \\ 1/4 & 1/4 & 1/4 & 1/4 \end{bmatrix} + \left(1 - \frac{4}{3}\alpha\right)^t \begin{bmatrix} 3/4 & -1/4 & -1/4 & -1/4 \\ -1/4 & 3/4 & -1/4 & -1/4 \\ -1/4 & -1/4 & 3/4 & -1/4 \\ -1/4 & -1/4 & -1/4 & 3/4 \end{bmatrix}$$

## Jukes-Cantor modelis

---

- Tarkim kad  $\alpha$  yra mažas.
- Mutacijos yra "retos"

Perėjimo matrica

$P(\alpha) = \begin{bmatrix} 1-\alpha & \alpha/3 & \alpha/3 & \alpha/3 \\ \alpha/3 & 1-\alpha & \alpha/3 & \alpha/3 \\ \alpha/3 & \alpha/3 & 1-\alpha & \alpha/3 \\ \alpha/3 & \alpha/3 & \alpha/3 & 1-\alpha \end{bmatrix}$

$p_0 = \left[ \frac{1}{4} \quad \frac{1}{4} \quad \frac{1}{4} \quad \frac{1}{4} \right]^T$

## Jukes-Cantor modelis

- $q(t)$  = sąlyginė tikimybė, kad bazė esamuoju laiko momentu ( $t$ ) momentu yra ta pati, kaip ir bazė pradiniu laiko momentu ( $t=0$ ).

$q(t)$

$$P(\alpha)^t = \begin{bmatrix} \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t \end{bmatrix}$$

# Jukes-Cantor modelis

- $q(t)$  = kokia dalis sekos pozicijų neturi stebimų pozicijų.

$q(t)$

$$P(\alpha)^t = \begin{bmatrix} \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t \end{bmatrix}$$

# Jukes-Cantor modelis

- $p(t)=1-q(t)$ =dalis sekos pozicijų, kuriose yra stebimos mutacijos.

$q(t)$

$$P(\alpha)^t = \begin{bmatrix} \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t \end{bmatrix}$$

$p(t) = 1 - q(t)$



# Jukes-Cantor modelis

- $p(t)=1-q(t)$ =dalis sekos pozicijų, kuriose yra stebimos mutacijos.

$q(t)$

$$P(\alpha)^t = \begin{bmatrix} \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t \end{bmatrix}$$

$p(t) = 1 - q(t)$

# Jukes-Cantor modelis

- p gali būti nustatyta lyginant dvi duotas sekas

$q(t)$

$$P(\alpha)^t = \begin{bmatrix} \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t \\ \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} - \frac{1}{4} \left(1 - \frac{4}{3} \alpha\right)^t & \frac{1}{4} + \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t \end{bmatrix}$$

$p(t) = 1 - q(t)$

## Example from 4.1

---

Dalis pozicijų, kurose stebimos mutacijos

$$p = \frac{2}{18} = 0.11$$

S0 : ATGTCGCCTGATAATGCC...



S2 : ATGCCGCGTGATAATGCC...

Sekoje stebimos mutacijos: 2

## Jukes-Cantor Atstumas

---

- Žinomam  $p$  (ir  $t$ ), J-C atstumas tarp dviejų sekų  $S_0$  ir  $S_1$  apibrėžiamas taip:

$$d_{JC}(S_0, S_1) = -\frac{3}{4} \ln \left( 1 - \frac{4}{3} p \right)$$

$S_0$  : ATGTCGCCTGATAATGCC...

⋮

$S_1$  : ATGCCGCGTGATAATGCC...

## Jukes-Cantor Atstumas

---

- Žinomam  $p$  (ir  $t$ ), J-C atstumas tarp dviejų sekų  $S_0$  ir  $S_1$  apibrėžiamas taip:

$$d_{JC}(S_0, S_1) = -\frac{3}{4} \ln \left( 1 - \frac{4}{3} p \right)$$

Kodėl?

$S_0$  : ATGTCGCCTGATAATGCC...

⋮

$S_1$  : ATGCCGCGTGATAATGCC...

# Jukes-Cantor Atstumas

---

$\alpha$ =bazės (simbolio) pakeitimo į kitą dažnis [pakaitų sk. per poziciją per laiko vienetą]

$t$ =laiko vienetų skaičius

$\alpha t$ =pakaitų sk. per poziciją įvykęs per  $t$  laiko vienetų

# Jukes-Cantor Atstumas

$\alpha$ =bazės (simbolio) pakeitimo į kitą dažnis [pakaitų sk. per poziciją per laiko vienetą]

$t$ =laiko vienetų skaičius

$\alpha t$ =pakaitų sk. per poziciją įvykęs per  $t$  laiko vienetų

$p(t)$  - dalis sekos pozicijų, kuriose yra stebimos mutacijos.

$$p = \frac{3}{4} - \frac{3}{4} \left( 1 - \frac{4}{3} \alpha \right)^t$$

$$t = \frac{\ln \left( 1 - \frac{4}{3} p \right)}{\ln \left( 1 - \frac{4}{3} \alpha \right)} \approx \frac{\ln \left( 1 - \frac{4}{3} p \right)}{-\frac{4}{3} \alpha}$$

kai  $\alpha$  yra mažas

# Jukes-Cantor Atstumas

$\alpha$ =bazės (simbolio) pakeitimo į kitą dažnis [pakaitų sk. per poziciją per laiko vienetą]

$t$ =laiko vienetų skaičius

$\alpha t$ =pakaitų sk. per poziciją įvykęs per  $t$  laiko vienetų

$$p = \frac{3}{4} - \frac{3}{4} \left(1 - \frac{4}{3} \alpha\right)^t$$

$$t = \frac{\ln\left(1 - \frac{4}{3} p\right)}{\ln\left(1 - \frac{4}{3} \alpha\right)} \approx \frac{\ln\left(1 - \frac{4}{3} p\right)}{-\frac{4}{3} \alpha}$$

$$\alpha t \approx -\frac{3}{4} \ln\left(1 - \frac{4}{3} p\right)$$

K



## Jukes-Cantor Atstumas

---

Stebimas atstumas tarp sekų  $d$   
tai realus atstumas tarp sekų:

$$K \approx -\frac{3}{4} \ln\left(1 - \frac{4}{3} d\right)$$

Tai yra Jukes-Cantor formulė (įsiminkit).

## Pavyzdys

---

Tarkim 40-bazių ilgio pirmąją ir dabartinę seką yra:

$S_0 : ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT$

$S_1 : ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC$

$S_1 \setminus S_0$	$A$	$G$	$C$	$T$
$A$	7	0	1	1
$G$	1	9	2	0
$C$	0	2	7	2
$T$	1	0	1	6

## Pavyzdys

Tarkim 40-bazių ilgio pirmykštė ir dabartinė seka yra:

$S_0$  : *ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT*

$S_1$  : *ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC*

$S_1 \setminus S_0$	A	G	C	T
A	7	0	1	1
G	1	9	2	0
C	0	2	7	2
T	1	0	1	6

$$p = \frac{11}{40} = 0.275$$

$$d_{JC} = -\frac{3}{4} \ln \left( 1 - \frac{4}{3} \cdot \frac{11}{40} \right) \approx 0.3426$$

## Pavyzdys

0.275 stebimų pakaitų per poziciją dažnis.

0.3426 prognozuojamas realiai įvykusių pakaitų per poziciją dažnis

$S_0$  : ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT

$S_1$  : ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC

$S_1 \setminus S_0$	A	G	C	T
A	7	0	1	1
G	1	9	2	0
C	0	2	7	2
T	1	0	1	6

$$p = \frac{11}{40} = 0.275$$

$$d_{JC} = -\frac{3}{4} \ln \left( 1 - \frac{4}{3} \cdot \frac{11}{40} \right) \approx 0.3426$$

## Pavyzdys

11 stebimų pakaitų

13.7 suprognozuotų pakaitų.

$S_0 : ACTTGTCGGATGATCAGCGGTCCATGCACCTGACAACGGT$

$S_1 : ACATGTTGCTTGACGACAGGTCCATGCGCCTGAGAACGGC$

$S_1 \setminus S_0$	A	G	C	T
A	7	0	1	1
G	1	9	2	0
C	0	2	7	2
T	1	0	1	6

$$p = \frac{11}{40} = 0.275$$

$$d_{JC} = -\frac{3}{4} \ln \left( 1 - \frac{4}{3} \cdot \frac{11}{40} \right) \approx 0.3426$$

# Jukes-Cantor Atstumas

---

Jukes-Cantor formulė:

$$K \approx -\frac{3}{4} \ln\left(1 - \frac{4}{3} d\right)$$

Esant mažam  $d$   $\ln(1+x) \approx x$  :  $K \approx d$


faktinis atstumas  $\approx$  stebimas atstumas

Esant mutacijų įsotinimui:  $d \uparrow \frac{3}{4}$  :  $K \rightarrow \infty$

Jei pasikeitė 3/4 lyginamų sekų bazių - atstumas tampa nebenustatomas.

Atsitiktinėms sekoms JC atstumo apskaičiuoti negalima.

$$K \approx -\frac{3}{4} \ln\left(1 - \frac{4}{3}d\right)$$



## Jukes-Cantor Atstumas. Dispersija

---

Jei  $K = f(d)$ , tuomet  $\delta K = \left( \frac{\partial K}{\partial d} \right) \delta d \Rightarrow \delta K^2 = \left( \frac{\partial K}{\partial d} \right)^2 \delta d^2$

Taigi  $\text{Var}(K) = \left( \frac{\partial K}{\partial d} \right)^2 \text{Var}(d)$

Sekų atsiradimas iš pradinės, kurių ilgis  $n$  ir pakaitų dažnis  $d$  yra binminis procesas:  $\text{Prob}(k) = \binom{n}{k} d^k (1-d)^{n-k}$

ir su tokia dispersija:  $\text{Var}(d) = d(1-d)/n$

O pagal Jukes-Cantor formulę:  $\frac{\partial K}{\partial d} = \frac{1}{1 - \frac{4}{3}d}$



# Jukes-Cantor Atstumas. Dispersija

---

dispersija:  $\text{Var}(d) = d(1-d)/n$


O pagal Jukes-Cantor formulę:

$$\frac{\partial K}{\partial d} = \frac{1}{1 - \frac{4}{3}d}$$

Taigi:


$$\text{Var}(K) \approx \frac{d(1-d)}{n(1 - \frac{4}{3}d)^2}$$

**Var(K)**



# Jukes-Cantor Atstumas.

1000 bp ilgio sekos evoliucijos modeliavimas. Pakaitų dažniai pagal JC prielaidas.



## Kimura 2-parametrų atstumas

---

- Ne visi pakaitai vienodai tikėtini.
- Tranzicija jos tikimybė sekos pozicijoje ( $G \leftrightarrow A$  ir  $T \leftrightarrow C$ ) yra  $\alpha$
- Transversijos tikimybė ( $G \leftrightarrow T$ ,  $G \leftrightarrow C$ ,  $A \leftrightarrow T$ , and  $A \leftrightarrow C$ ) sekos pozicijoje yra  $\beta$

## Kimura 2-parametrų atstumas

---

Atitinkamo Markovo proceso pakaitų matrica:

$$P(\alpha, \beta) = \begin{bmatrix} -\alpha - 2\beta & \alpha & \beta & \beta \\ \alpha & -\alpha - 2\beta & \beta & \beta \\ \beta & \beta & -\alpha - 2\beta & \alpha \\ \beta & \beta & \alpha & -\alpha - 2\beta \end{bmatrix}$$

## Kimura 2-parametrų atstumas

---

Pot generacijų pakaitų tikimybė bus:

$$P(t) = P_{K2P}^t$$

Reikia nustatyti  $P(t)$ :

**tikrines vertes  $\{\lambda_i\}$**

**ir tikrinius vektorius  $\{v_i\}$**

## Kimura 2-parametrų atstumas

Spektrinė dekompozicija  $M(t)$ :

$$P_{K2P}^t = \sum_i \lambda_i^t \mathbf{v}_i \mathbf{v}_i^T$$

$$P^n = \begin{bmatrix} 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 \end{bmatrix} + (1 - 4\beta)^n \begin{bmatrix} 0.25 & 0.25 & -0.25 & -0.25 \\ 0.25 & 0.25 & -0.25 & -0.25 \\ -0.25 & -0.25 & 0.25 & 0.25 \\ -0.25 & -0.25 & 0.25 & 0.25 \end{bmatrix} \\ + (1 - 2(\alpha + \beta))^n \begin{bmatrix} 0.5 & -0.5 & 0 & 0 \\ -0.5 & 0.5 & 0 & 0 \\ 0 & 0 & 0.5 & -0.5 \\ 0 & 0 & -0.5 & 0.5 \end{bmatrix}$$

## Kimura 2-parametrų atstumas

---

Nustatykite kokia dalis bus tranzicijų per poziciją per  $t$  generacijų :  $P(t)$

Nustatykite kokia dalis bus transversijų per poziciją per  $t$  generacijų :  $Q(t)$

Atstumas tarp sekų:  $K \approx -\frac{1}{2} \ln(1-2P-Q) - \frac{1}{4} \ln(1-2Q)$

Pakaitų dalis  $d = P + Q \rightarrow \text{Jukes-Cantor}$



## Kimura 2-parametrų atstumas

---

$$P^n = \begin{bmatrix} 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 \end{bmatrix} + (1-4\beta)^n \begin{bmatrix} 0.25 & 0.25 & -0.25 & -0.25 \\ 0.25 & 0.25 & -0.25 & -0.25 \\ -0.25 & -0.25 & 0.25 & 0.25 \\ -0.25 & -0.25 & 0.25 & 0.25 \end{bmatrix} \\ + (1-2(\alpha+\beta))^n \begin{bmatrix} 0.5 & -0.5 & 0 & 0 \\ -0.5 & 0.5 & 0 & 0 \\ 0 & 0 & 0.5 & -0.5 \\ 0 & 0 & -0.5 & 0.5 \end{bmatrix}$$

## Kiti evoliucijos modeliai

---

- Atskiria kitus tranzicijos transvercijos tipus - naudoja daugiau parametru
- ...daugybė kitų metodų. Naudojama net 15-os parametru
- Esmini trūkumas egzistuojančių metodų yra tai, kad remiamasi prielaida, kad simetrinių mutacijų tikimybės yra vienodos

$$\text{prob}(A \rightarrow T) = \text{prob}(T \rightarrow A)$$

- Gana daug stiprių įrodymų, kad ši prielaida yra klaidinga....
- Ateities iššūkiai...

## **Pavyzdys. Ar neandartaliečiai yra tarp mūsų.**

---

- 206 mtDNA molekulės iš H. sapiens.
- 2 mtDNA molekulės iš H. neanderthaliensis bei 1856 paskiri fragmentai.
- Visi 208 mėginiai iš GenBanko.
- Homologinė seka 800 bp rasta visuose mėginiuose.

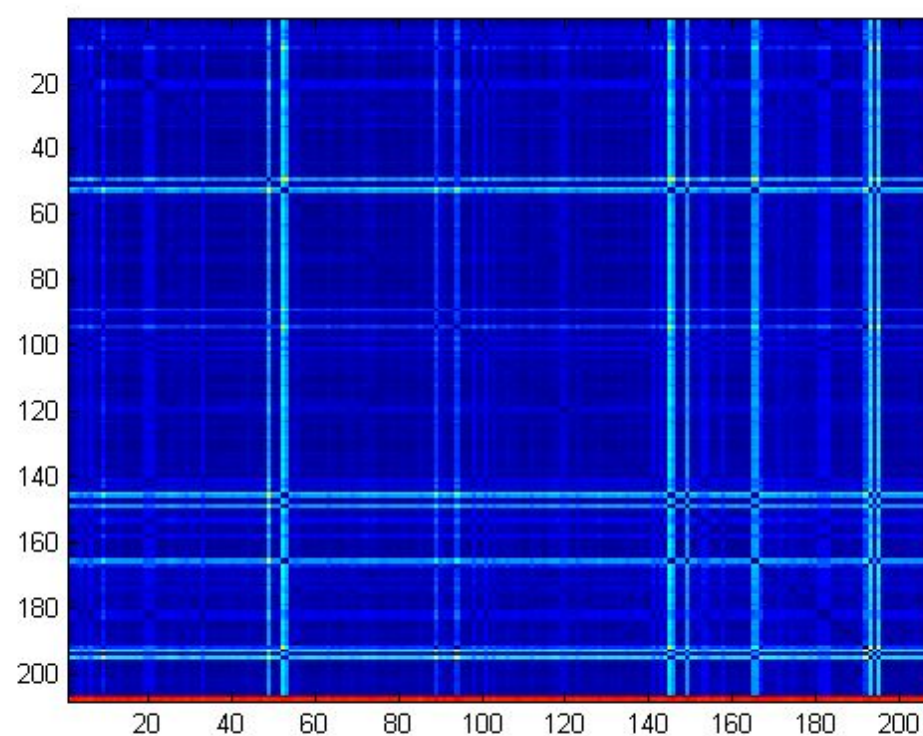
## **Pavyzdys. Ar neandartaliečiai yra tarp mūsų?**

---

- 206 mtDNA molekulės iš *H. sapiens*.
- 2 mtDNA molekulės iš *H. neanderthaliensis* bei 1856 paskiri fragmentai.
- Visi 208 mėginiai iš GenBanko.
- Homologinė seka 800 bp rasta visuose mėginiuose.

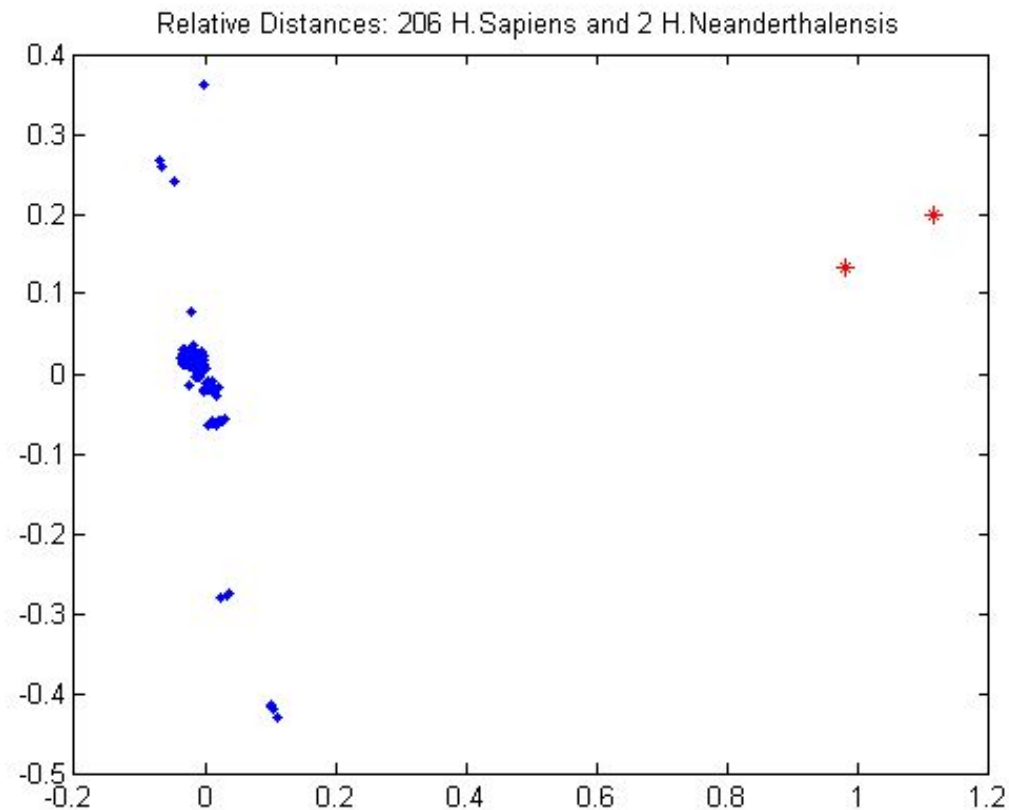
# Pavyzdys. Ar neandartaliečiai yra tarp mūsų?

---



# Pavyzdys. Ar neandartaliečiai yra tarp mūsų?

---



# Pavyzdys. Ar neandartaliečiai yra tarp mūsų?

